



RAPPORT DE STAGE

Valorisation de données PDF

SOUMIS PAR

Desbois-Renaudin Méo

THALES

THALES SERVICES NUMÉRIQUES

September 4, 2025

MAÎTRE DE STAGE :

Barriere Paul

SUPERVISEUR ÉCOLE :

Morandat Floréal

Résumé

Durant mon stage de fin d'études en tant que Data Scientist chez Thales Services Numériques (TSN), j'ai travaillé à l'élaboration d'un agent conversationnel basé sur la Retrieval-Augmented Generation (RAG) [3] pour répondre aux besoins d'accès à l'information dans les centrales nucléaires françaises. Celles-ci disposant de centaines de documents PDF techniques difficilement accessibles pour les opérateurs de terrain, mon objectif a été de concevoir une solution capable de retrouver et formuler des réponses précises à partir de ces documents.

J'ai exploré différentes approches pour répondre aux deux jalons principaux du projet, l'extraction de texte propre à partir de documents PDF et la génération de réponses cohérentes à partir de ces données. Cette phase a impliqué la comparaison de stratégies de parsing, de nettoyage et de segmentation du texte, ainsi que l'étude de systèmes multi-agents capables de sélectionner dynamiquement les outils nécessaires pour répondre aux requêtes des utilisateurs. Les résultats montrent que l'utilisation de layout parsing [8] [4] pour l'extraction de données, combinée à une approche multi-agent, alliant recherche vectorielle, interrogation de bases de données et lecture multimodale des documents, offre un bon compromis entre pertinence des réponses et temps de traitement, tout en restant extensible et adaptable aux besoins des utilisateurs.

J'ai finalement développé la solution choisie pour qu'elle soit entièrement déployable sur Google Cloud Platform, en incluant le code Python, la conteneurisation via Dockerfile, la mise en place de pipelines CI/CD pour le déploiement automatique, ainsi que l'utilisation de Terraform pour gérer l'infrastructure cloud. Ce projet m'a permis de consolider mes compétences en Data science, en évaluation de modèles et en ingénierie cloud, tout en contribuant à une problématique réelle.

Mots-clés : Data Science, RAG, LLM, Google Cloud, évaluation de performance, NLP, ingestion documentaire

Remerciements

Je tiens à exprimer ma gratitude à l'équipe CEGG de Thales Services Numériques pour son accueil chaleureux et son encadrement tout au long de ce stage. Je remercie tout particulièrement mon tuteur en entreprise, M. Barriere, pour son attention, ses conseils, sa disponibilité et son soutien au cours de mon parcours à Thales.

Je souhaite également remercier mon tuteur académique, M. Morandat, pour son encadrement sur le projet. Enfin, je remercie l'ensemble des collaborateurs de Thales et d'EDF qui ont contribué à rendre cette expérience enrichissante.

Sommaire

Résumé	1
1 Introduction	3
2 Contexte	4
2.1 L'entreprise Thales	4
2.2 Pourquoi ce choix ?	4
3 Description du sujet de stage	5
3.1 Problématique	5
3.2 Travaux préalables	5
3.3 Contraintes sur la solution	5
4 Recherche de solution	6
4.1 Extraction fidèle des données	6
4.1.1 Méthode	6
4.1.2 Métriques & résultats	8
4.1.3 Discussion	11
4.2 Génération augmentée (Agents LLM)	12
4.2.1 Prérequis sur le RAG	12
4.2.2 Méthode	13
4.2.3 Métriques & résultats	14
4.2.4 Discussion	15
5 Développement de la solution	17
5.1 Outils utilisés	17
5.2 Architecture de la solution	18
5.3 Implémentation	19
5.3.1 Développement python	20
5.3.2 Intégration continue	21
5.3.3 Infrastructure Cloud	21
5.3.4 Tests	21
6 Conclusion	23
Références	24
Annexes	25
A Annexe: Présentation du groupe Thales	25
B Annexe: Exemple de document pdf	29
C Annexe : Exemple de chunks pour les différents parsers	39

1 Introduction

Les grandes entreprises actuelles disposent d'énormes quantités d'information sous la forme de fichiers PDF (Portable Document Format), résultant d'un passé où tous les documents propres à une entreprise transitaient sous format papier et devaient être imprimés.

Aujourd'hui, suivant leurs politiques de modernisation, celles-ci veulent pouvoir accéder et valoriser les données présentes dans ces documents. Cependant, Le PDF étant un format propriétaire pensé pour être imprimé avant tout, en récupérer les données structurées de manière 100% fiable reste une tâche non résolue à ce jour.

C'est dans ce cadre que s'inscrit mon stage de fin d'études au sein de Thales Services Numériques. La branche de prestation de services de la firme Thales. L'entreprise EDF (Electricité de France), pour laquelle mon équipe Thales travaille, désire aujourd'hui valoriser ses données.

Celle-ci dispose notamment de centaines de PDF recensant les différents processus et règles à suivre pour les activités de maintenances des centrales nucléaires. Ces documents sont actuellement tenus par un support accessible par mail pour les employés ayant besoin de les consulter. Cette manière d'accéder à l'information contenue dans ces documents fait actuellement perdre beaucoup de temps aux employés, et surcharge parfois le support mail.

La problématique à laquelle j'ai été confronté peut donc se formuler ainsi :

Comment extraire et rendre disponible facilement des données contenues dans un corpus de documents PDF de taille moyenne, de manière fiable et optimisée?

Pour répondre à cette problématique, j'ai structuré mon travail en plusieurs étapes. La première consistait à comprendre précisément le besoin, à analyser le corpus de documents et à me former aux outils et services cloud nécessaires au projet.

La seconde étape a porté sur la recherche de solutions adaptées, en explorant différentes méthodes d'extraction et de valorisation des informations, ainsi que des approches basées sur les modèles de langage et les systèmes d'agents.

Enfin, la dernière phase a été consacrée à l'implémentation et au déploiement de la solution retenue, incluant la conception d'une architecture cloud scalable, le développement des pipelines de traitement et la mise en place de processus automatisés pour assurer la reproductibilité et la maintenabilité du système.

2 Contexte

Au cours de ma formation, j'ai choisi de me spécialiser en intelligence artificielle, un domaine en pleine expansion qui m'attire particulièrement par la diversité de ses applications. Convaincu de vouloir orienter ma carrière dans cette voie, je souhaitais effectuer un stage qui me permette d'approfondir mes compétences en data science et en traitement de données.

Je vais vous présenter en quoi ma future équipe à Thales a su proposer un sujet qui me corresponde, et qui me fasse découvrir des technologies complémentaires comme le déploiement dans le Cloud.

2.1 L'entreprise Thales

Thales est un groupe industriel français d'envergure internationale, spécialisé dans les hautes technologies, notamment dans les secteurs de l'aéronautique, de la défense, de la sécurité et du spatial. Présent dans plus de 50 pays, le groupe est reconnu pour sa capacité à concevoir et déployer des systèmes critiques où la sûreté et la fiabilité sont essentielles.

Au sein de Thales, l'entité Thales Services Numériques accompagne ses clients dans leur transformation numérique en proposant des solutions basées sur l'intelligence artificielle, le cloud, le big data ou encore la cybersécurité. C'est dans ce cadre que s'inscrit la collaboration avec EDF, qui a exprimé le besoin de développer un outil intelligent capable de faciliter l'accès à l'information technique dans ses activités de maintenance. L'enjeu est de réduire le temps de recherche documentaire et d'améliorer la réactivité des équipes face à des problématiques complexes, en s'appuyant sur les avancées récentes en IA générative.

Vous trouverez plus d'informations sur le groupe, ma branche ainsi que ma place dans l'entreprise en annexe A

2.2 Pourquoi ce choix ?

Les missions qui m'ont été proposées lors de ce stage correspondaient pleinement à mes aspirations : elles couvraient à la fois la data science, le traitement automatique de documents complexes et le déploiement dans un environnement cloud. Elles représentaient donc une occasion parfaite de progression et de découverte, en me permettant de mettre en pratique mes connaissances théoriques tout en développant de nouvelles compétences dans un contexte industriel exigeant.

Je voyais également dans ce stage une opportunité de m'intégrer à une équipe expérimentée, de comprendre concrètement les attentes d'un grand groupe comme Thales en matière de solutions d'IA, et de participer à un projet ayant un impact opérationnel réel. Ce choix s'inscrit ainsi dans la continuité de mon projet professionnel, en renforçant mon expertise dans un domaine que je souhaite poursuivre à long terme.

3 Description du sujet de stage

L'entreprise cliente, EDF, emploie de nombreux ouvriers de maintenance travaillant dans les centrales nucléaires. Pour informer ceux-ci sur les démarches à suivre et les consignes à respecter, elle dispose de nombreux documents PDF. Ce sont des documents de spécification et de description de processus.

L'accès rapide et fiable à ces documents techniques est essentiel pour les ouvriers de maintenance, mais le système actuel est lent et complexe. Ce projet propose une solution basée sur l'IA générative pour faciliter la recherche et l'extraction d'informations pertinentes dans ces documents.

3.1 Problématique

Les documents sont portés sur un système informatique de support accessible uniquement par mail. Une demande doit être faite pour accéder à l'un de ces documents.

Ce système ralentit le travail des employés :

- Les demandes entraînent un délai avant de pouvoir lire le document recherché.
- Le support est parfois surchargé.
- Il est difficile pour un employé de savoir exactement quel document contient l'information recherchée.

3.2 Travaux préalables

Suivant cette problématique, un court POC (Proof of Concept) avait été réalisé préalablement à mon stage. Celui-ci avait démontré la possibilité de résoudre cette problématique grâce à un agent conversationnel déployé sur le Cloud, et avait ouvert des portes à de nouvelles perspectives d'amélioration et d'optimisation.

3.3 Contraintes sur la solution

Cette problématique définit donc le sujet de stage, suivant lequel ma mission consiste à trouver une solution, puis procéder au développement et à l'évaluation de l'efficacité de celle-ci.

Cette solution doit respecter les règles cybersécurité d'EDF, et être compatible avec les applications internes du SI d'EDF. pour cela, l'application finale doit utiliser les technologies suivantes :

- **Langage** : Python
- **Cloud** : Google Cloud Platform (GCP)
- **Modèles** : Vertex AI, Gemini, Google ADK
- **Déploiement** : Docker, Terraform

4 Recherche de solution

Suivant le POC effectué au préalable, je me suis naturellement tourné vers le développement d'une application Chatbot. Ayant la possibilité de retrouver les données des documents grâce à un système RAG (Retrieval-Augmented Generation), modèle introduit par Lewis et al. [3]. Celui-ci combine un module de récupération de document (souvent via recherche vectorielle) à un modèle génératif de langage.

Pour y parvenir, nous avons identifié plusieurs étapes clés pour la performance finale de l'agent conversationnel :

- L'extraction de données textuelles propres (chunks) des documents PDF
- La génération d'une réponse à l'utilisateur en utilisant ces données dans le prompt

4.1 Extraction fidèle des données

Les documents traités étaient censés suivre un format précis, pour qu'un employé connaisseur du format puisse retrouver facilement les informations. Cependant, même si les documents se ressemblent effectivement visuellement, le fichier pdf en lui-même peut-être très différent. Cela exclut une approche simple à base de reconnaissance de patternes regex. Un travail de parsing rigoureux a été nécessaire pour transformer ces documents en texte structuré, adapté à une ingestion RAG :

- Nettoyage et segmentation de texte
- Structuration des documents techniques
- découpage en paragraphes possédant de la valeur d'information

La complexité principale de cette phase réside dans la diversité des formats PDF traités, ainsi que dans l'hétérogénéité de leur structuration logique.

4.1.1 Méthode

L'objectif de cette étape était de transformer des documents PDF bruts, souvent hétérogènes dans leur structure, en données textuelles exploitables par une architecture RAG. Pour y parvenir, j'ai comparé plusieurs approches de parsing et de segmentation.

Dans un document PDF, le texte n'est pas stocké comme un flux linéaire, mais sous forme de caractères individuels (glyphes) positionnés à des coordonnées précises sur la page. Cette organisation nous amène à la première étape, retrouver des phrases structurées à partir des glyphes.

- **Extraction naïve par règles géométriques** : cette approche simple néanmoins efficace et simple, rassemble les caractères en mots et lignes grâce à leur position (x,y). Elle présente l'avantage de la simplicité et la rapidité, mais souffre de problèmes fréquents liés à l'ordre du texte, à l'apparition de caractères parasites, ainsi qu'à l'absence d'informations de mise en page (titres, tableaux, encadrés).

- **Extraction assistée par *layout parsing*** : pour dépasser les limites de la méthode précédente, j’ai exploré des approches basées sur des modèles de langage *RT-DETR* [8] en prenant comme exemple la librairie récente *Docling* [4]. Ces méthodes exploitent la structure visuelle des documents (zones, colonnes, titres, paragraphes) afin de reconstruire un texte plus fidèle au format logique original.

Dans le domaine de la vision par ordinateur, les modèles dits de type **YOLO** (You Only Look Once) [6] ont marqué une étape importante en rendant la détection d’objets rapide et efficace. Leur principe repose sur la prédiction des **Bounding box** et des classes directement à partir de l’image, en un seul passage du réseau. Transposée au contexte des documents numériques, cette idée trouve une application naturelle dans le *layout parsing* : un modèle peut traiter une page PDF comme une image et identifier les différentes zones qui la composent (titres, paragraphes, figures, tableaux, etc.), facilitant ainsi une extraction structurée du contenu.

Les approches récentes en vision par ordinateur offrent une alternative plus robuste aux règles géométriques. Parmi elles, les modèles de la famille **DETR** (DEtection TRansformer) [1] formulent la détection d’objets comme une tâche de prédiction directe à partir de requêtes apprises. Ces modèles n’ont plus besoin de définir manuellement des heuristiques pour grouper les glyphs : ils apprennent à reconnaître et localiser les éléments d’intérêt à partir de la structure visuelle de la page.




Figure 1: Architecture d’un modèle DETR [1] : Un transformer à tête MLP pour détection de bounding box

Leur déclinaison optimisée, **RT-DETR** (Real-Time DETR) [8], conserve les principes de DETR tout en allégeant l’architecture pour permettre une utilisation plus rapide. Dans le contexte de l’analyse de documents, l’idée est de tirer parti de ces modèles en les *affinant* (*fine-tuning*) sur des jeux de données annotés tels que DocLayNet [5], où chaque zone d’une page (titre, paragraphe, figure, tableau, note de bas de page, etc.) est étiquetée.

Une fois adaptés à ce domaine, ces modèles se comportent comme un *YOLO appliqué aux PDF* : ils détectent les différentes régions et leur attribuent une classe, ce qui permet de reconstruire un texte enrichi de sa mise en page logique.

Une fois le texte extrait, j’ai procédé à un post-traitement afin de le nettoyer et le rendre exploitable, car les documents PDF contiennent souvent de nombreux caractères parasites et des artefacts liés à l’extraction. J’ai commencé par supprimer les caractères mal encodés ou traduits incorrectement par l’outil de parsing, puis j’ai retiré systématiquement les entêtes et pieds de page récurrents. J’ai ensuite homogénéisé l’encodage des textes pour éviter les incohérences entre documents et appliqué une normalisation supplémentaire afin de corriger les accents et ajuster les retours à la ligne mal placés. Cette étape m’a permis d’obtenir un texte structuré et continu, prêt à être segmenté en chunks pertinents.

Pour la segmentation, j’ai exploré plusieurs approches afin de créer des segments significatifs et adaptés à l’ingestion par un modèle RAG. Dans un premier temps, j’ai testé une méthode naïve consistant à découper le texte en segments de taille fixe, par exemple 512 caractères ou tokens. Cette approche était simple et rapide à mettre en œuvre, mais elle ne prenait pas en compte les limites sémantiques des paragraphes et pouvait couper des phrases ou des passages importants.

J’ai ensuite expérimenté un découpage sémantique, utilisant des règles et heuristiques pour identifier des points de rupture logiques dans le texte, comme la ponctuation, la fin de paragraphes ou les changements de thème. Cette méthode m’a permis de produire des chunks plus cohérents et respectant mieux la logique interne du texte.

Enfin, j’ai envisagé un découpage par *section*, dans lequel j’essaie de détecter automatiquement la hiérarchie des titres et sous-titres afin de segmenter le document selon ses sections thématiques. Pour cela, j’ai testé plusieurs techniques :

- **Layout parsing**: Dans le cas de l’utilisation d’un modèle de layout parsing, les éléments de pdfs formatés comme des titres sont retrouvés par définition. Ceux-ci ne correspondant pas forcément à des titres de sections, j’ai alors mis en place une sous solution qui reconnaît grâce à des patronnes lesquels de ces titres sont des sections.
- **Prompt engineering**: Une autre méthode que j’ai explorée est l’utilisation d’un LLM pour repérer les différentes sections. En se fondant sur des exemples donnés dans le prompt, cette méthode retrouve les différentes sections du PDF et découpe les chunks par section retrouvée.

J’ai évalué ces différentes combinaisons afin de trouver le meilleur compromis entre qualité du texte extrait, fidélité de la structuration et granularité des chunks. Les résultats détaillés de cette évaluation sont présentés dans la section suivante.

4.1.2 Métriques & résultats

Afin d’évaluer les différentes méthodes de parsing et de segmentation, j’ai défini un ensemble de métriques permettant de comparer leur efficacité indépendamment des résultats finaux du RAG:

- **Intégrité des passages clés** : mesure de la préservation des sections importantes (par ex. via similarité de Levenshtein entre texte original et texte découpé).

- **Taille moyenne des chunks** : à minimiser, car des chunks trop longs réduisent la pertinence des embeddings.
- **Taux de couverture des sections** : pourcentage de sections documentaires correctement retrouvées dans les chunks, sur un échantillon de 5 PDF annotés manuellement.
- **Taille totale des données** : à minimiser afin d’optimiser le stockage et la recherche vectorielle.
- **Évaluation par LLM** (*LLM-as-a-Judge*) : estimation de la valeur informationnelle des chunks, en jugeant leur pertinence et leur cohérence contextuelle.




Figure 2: Score d’intégrité des méthodes d’extractions comparées à la taille des données extraites

Sur cette base de métriques, j’ai évalué les approches les plus prometteuses de parsing et de segmentation, chacune présentant des avantages et des limites spécifiques, ainsi que deux méthodes témoins. La première, **RawParser**, repose sur une extraction naïve avec **pdfminer**, sans aucun nettoyage et avec un découpage purement naïf. Elle m’a servi de référence minimale pour évaluer les gains des méthodes plus élaborées. La seconde, **CleanedParser**, utilise la même extraction naïve mais avec un pipeline complet de nettoyage (suppression des artefacts, normalisation, retrait des en-têtes et pieds de page), ce qui permet d’isoler l’apport du prétraitement par rapport à l’approche brute.




Figure 3: Evaluation des méthodes d’extractions à travers plusieurs métriques

J’ai ensuite testé **GeminiParser**, qui s’appuie également sur une extraction naïve, mais enrichie d’un nettoyage rigoureux et surtout d’un découpage assisté par LLM. Dans cette approche, le modèle est chargé d’identifier et de restituer la hiérarchie des sections, permettant d’obtenir des chunks correspondant davantage à la structure logique du document. Cette méthode a montré un potentiel intéressant, notamment sur des documents longs et complexes.

Une autre piste explorée est **DoclingParser**, qui exploite un parsing par mise en page à l’aide de **Docling**. L’extraction tient compte de la structure visuelle du document (colonnes, encadrés, titres), et le découpage repose sur les segments proposés par l’outil. Cette approche est plus riche que les parseurs naïfs, mais le découpage n’est pas toujours aligné parfaitement avec les sections logiques attendues.

Enfin, j’ai développé **LayoutParser**, également basé sur **Docling** pour l’extraction, mais en combinant le nettoyage avec un découpage par section inspiré de la structuration hiérarchique du document. L’objectif était de rapprocher le résultat final d’une segmentation logique fidèle à l’organisation initiale des documents techniques.

Ces différentes approches constituent un panel représentatif de stratégies possibles, allant de la plus simple (RawParser) à la plus structurée (LayoutParser). Elles me servent de base de comparaison pour sélectionner les pipelines les plus prometteurs en vue d’une intégration complète dans l’architecture RAG.

```

## 2.3.2 Interactions dans le milieu planctonique
Au cours de leur vie pelagique, les larves de langoustes interagissent avec d'autres organismes marins. Si des conditions envier
Journal de bord des observations :
Nota: enregistrer ces observations dans les journaux de bord permet de retracer les facteurs de succes ou d'echec des generatio
- · Noter les especes planctoniques presentes dans les echantillons.
- · Documenter les interactions observees (predation, competition).
-----
## 1.1 Objet du document
Ce document decrit les etapes cles du cycle de vie de la langouste, de la ponte des œufs a l'emergence des juveniles, afin de c

```

Figure 4: Chunks extraits avec le **LayoutParser** (sur des **données factices**, pdf d'exemple de l'annexe B): on observe des section bien extraites. Pour voir les chunks émis par les autres parsers, consultez l'annexe C

4.1.3 Discussion

L'analyse des différentes approches met en évidence plusieurs enseignements importants. Tout d'abord, le nettoyage du texte apparaît comme une étape absolument indispensable, en particulier la suppression des en-têtes et pieds de page récurrents. Sans ce prétraitement, les chunks générés contiennent trop de bruit pour être véritablement exploitables, quelle que soit la méthode de segmentation employée.

Concernant la reconstitution de la structure documentaire, seules les approches **GeminiParser** et **LayoutParser** étaient éligibles à la métrique **sections retrouvées**, car ce n'était pas l'objectif des autres parsers. Entre ces deux méthodes, j'ai constaté que le layout parsing offrait une meilleure robustesse et une plus grande efficacité que l'utilisation d'un LLM pour identifier les sections. Le recours au LLM pour le chunking apporte néanmoins de la flexibilité, mais reste plus sensible aux variations du texte et à la qualité de l'extraction initiale.

L'évaluation par un LLM utilisé comme juge (donnant une note sur la qualité des chunks) est utile pour comparer deux solutions entre elles, mais moins pertinente en tant que métrique absolue : le modèle peut fournir des indications de tendance, mais il n'offre pas un score directement exploitable. Mais cette métrique a notamment montré que l'approche fondée uniquement sur **DoclingParser** a certaines limites, liées à un texte mauvais nettoyage du texte dans le cas de nos documents EDF, ce qui réduit la qualité des segments générés, et est difficile à corriger par la suite.

J'ai donc hésité entre **GeminiParser**, qui repose sur un chunking par LLM, et **LayoutParser**, qui combine extraction par layout parsing, nettoyage et un algorithme de segmentation par section. Finalement, c'est cette dernière approche que j'ai retenue comme base de référence. Elle s'est montrée plus efficace et plus généraliste, tout en permettant de préserver la hiérarchie des sections, ce qui est particulièrement précieux dans le contexte de documents techniques complexes.

Il convient toutefois de nuancer ces conclusions, car les métriques ont été calculées sur un nombre restreint de documents : un seul PDF dans la plupart des cas, et un ensemble de cinq documents pour l'évaluation des sections. L'échantillon reste donc limité, ce qui réduit la précision et la portée statistique des mesures. Une évaluation sur un corpus plus large serait nécessaire pour confirmer la robustesse de ces résultats.

Après avoir trouvé une méthode d'extraction de données efficace, il faut trouver comment présenter ces données aux métiers ciblés.

4.2 Génération augmentée (Agents LLM)

Conformément aux attentes exprimées par le client, la solution retenue devait prendre la forme d'un *chatbot*. Celui-ci doit être capable de répondre de manière satisfaisante au plus grand nombre de questions que les équipes métiers pourraient poser, qu'elles portent sur des points techniques précis ou sur des aspects plus globaux de la documentation. L'idéal est que l'interaction avec le chatbot soit aussi enrichissante et fluide qu'une discussion avec un employé expérimenté, offrant à la fois des explications détaillées et une vision synthétique du corpus.

La difficulté réside donc dans la conception d'un système capable de naviguer entre différents niveaux de granularité de l'information. Le chatbot doit en effet pouvoir fournir des réponses extrêmement spécifiques, par exemple liées à une procédure technique particulière, tout en étant capable de répondre à des requêtes plus globales telles que : "De combien de documents de type RU disposes-tu ?". Cette double exigence impose de réfléchir soigneusement à la méthode de génération de réponses augmentée par la récupération documentaire, et d'en comparer plusieurs variantes avant de retenir la plus adaptée au contexte industriel.

4.2.1 Prérequis sur le RAG

L'essor des modèles de langage de grande taille (LLM) trouve ses racines dans l'introduction de l'architecture Transformer par Vaswani et al. [7]. Cette approche a permis des avancées majeures en NLP, notamment grâce à cette architecture fondée uniquement sur l'attention, rendant l'entraînement beaucoup plus parallélisable. Depuis, les LLM se sont imposés comme des outils extrêmement performants pour la compréhension et la génération de langage naturel.

Toutefois, leur utilisation brute présente une limite importante : les modèles ne possèdent pas de mémoire persistante sur des documents externes et sont contraints par leur fenêtre de contexte. Pour répondre à ce problème, la méthode de *Retrieval-Augmented Generation* (RAG), introduite par Lewis et al. [3], propose d'augmenter les capacités d'un LLM en lui fournissant des informations supplémentaires directement dans le prompt, issues d'une base documentaire externe.

La partie la plus critique de ce processus réside dans la phase de *retrieval*. Concrètement, les documents sont découpés en segments cohérents (étape d'extraction décrite plus haut), puis encodés en vecteurs grâce à un modèle d'embedding. Ces vecteurs sont stockés dans une base de recherche vectorielle, où chaque requête de l'utilisateur est elle-même encodée avant d'être comparée à l'ensemble des chunks afin de retrouver les passages les plus pertinents. Dans mon projet, j'ai utilisé les bibliothèques de Google Cloud, basée sur leur algorithme ScaNN [2], optimisé pour la recherche à grande échelle.

Le système RAG de base repose donc sur ce principe : à chaque requête, une recherche vectorielle est effectuée pour sélectionner les chunks pertinents, qui sont ensuite insérés dans le prompt transmis au modèle génératif. Cette méthode est efficace, mais elle présente certains défauts, notamment une dépendance systématique à la recherche vectorielle pour chaque question, ce qui peut devenir coûteux et redondant. Ces limites ouvrent la voie à des systèmes plus élaborés, comme les agents, qui deviennent la norme pour le traitement de données par LLM.

4.2.2 Méthode

Un agent est, par définition un LLM auquel des outils (fonctions) ont été mis à disposition. Pour y parvenir, un modèle foundation a subi un fine-tuning pour générer une séquence de token spécifique signifiant 'appel de fonction'. L'agent prend donc la décision de l'outil à mobiliser en fonction de la requête de l'utilisateur et du contexte. Cette approche présente plusieurs avantages : elle permet d'exploiter différents outils selon les besoins et de choisir de ne pas utiliser certains outils lorsque cela n'est pas nécessaire. Cela permet aussi de combler certaines limites des LLM, notamment l'accès à des données externes ou la réalisation de calculs complexes, et ouvre également la voie à la conception de systèmes multi-agents pouvant collaborer ou se spécialiser sur différentes tâches.

C'est ce type de solutions que j'ai comparé dans cette section pour identifier l'approche la plus adaptée aux besoins du client.

Nous pouvons noter plusieurs sources d'information disponibles pour l'agent. Celles-ci comprennent les chunks extraits et nettoyés à partir des documents, les métadonnées associées à chaque PDF, ainsi que les documents complets eux-mêmes, qui peuvent être lus par un modèle Gemini multimodal capable d'interpréter le contenu comme une image.

Différents outils ont été envisagés pour être intégrés à l'agent :

- **vector_search** : effectue une recherche vectorielle sur la question de l'utilisateur pour retrouver les passages les plus pertinents.
- **sql_query** : exécute des requêtes SQL sur les bases de données cloud afin de fournir des réponses basées sur des informations structurées.
- **document_list** : permet de lister simplement les documents disponibles dans le système.
- **document_finder** : sous-agent agissant comme outil, chargé de retrouver le nom d'un document à partir d'indices, dans le but de le faire lire ultérieurement par le modèle multimodal.
- **document_specialist** : sous-agent capable de lire un PDF en multimodal (comme une image) pour en extraire des informations détaillées.

Les approches finales comparées incluent plusieurs configurations. La première consiste en un agent simple disposant uniquement de deux outils : **vector_search** et **sql_query**.

La seconde correspond à un système multi-agent plus avancé, intégrant `vector_search`, `sql_query`, `document_finder` et la lecture de PDF via le modèle multimodal `document_specialist`, comme illustré en figure 5. Enfin, une approche alternative a été testée avec un agent dépourvu de recherche vectorielle, ne disposant que de `document_finder` et du sous-agent multimodal `document_specialist` pour répondre aux requêtes des utilisateurs.




Figure 5: Structure agentique de la solution retenue

4.2.3 Métriques & résultats

Évaluer la performance d'un agent constitue un véritable défi, car il s'agit avant tout d'estimer sa capacité à satisfaire les besoins des métiers. Or, les utilisateurs posent souvent des questions variées, parfois imprévues, ce qui rend difficile la définition de métriques objectives et universelles. Lors d'un POC préalable à mon stage, un petit jeu d'essais d'environ vingt questions métiers avait déjà montré cette difficulté, avec de nombreux cas particuliers non anticipés.

Afin de mieux approcher cette notion de « satisfaction métier », j'ai construit un jeu de données annoté, basé sur ces essais, en définissant pour chaque question une réponse attendue. Ce jeu de données ne couvre évidemment pas toute la diversité des requêtes possibles, mais il constitue une base pragmatique pour comparer les différentes approches testées.

Les métriques utilisées sur ce jeu de données sont les suivantes :

- **Trajectoire d'outils** : évalue si l'agent a utilisé les outils attendus pour résoudre la question. Cette métrique permet de vérifier la cohérence du raisonnement suivi par rapport aux intentions initiales.
- **Match de réponse finale** : comparaison automatique entre la réponse générée et la réponse attendue, en utilisant le score rouge de similarité, basé sur les permutations.

Cette approche reste imparfaite, car une même réponse peut être formulée de plusieurs manières tout en étant correcte.

- **LLM as a judge** : une autre instance de LLM compare la réponse obtenue et la réponse attendue, puis attribue une note qualitative. Bien que cette approche reflète mieux l'évaluation humaine, elle reste approximative et sujette à variabilité.
- **Temps d'exécution** : Compare les moyennes de temps d'exécution.

Le ROUGE score est un choix couramment utilisé pour comparer un résumé machine à un résumé humain (réalité terrain). Il calcule le recall¹ du nombre de N-uplets présent dans le texte testé par rapport au texte de référence. Dans notre cas, ROUGE-1 calcule le recall pour les mots. J'ai estimé que ce score est utile ici car il reste généraliste et est rapide à calculer

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Reference Summaries}\}} \sum_{\text{gram}_n \in S} \min(\text{Count}_{\text{cand}}(\text{gram}_n), \text{Count}_S(\text{gram}_n))}{\sum_{S \in \{\text{Reference Summaries}\}} \sum_{\text{gram}_n \in S} \text{Count}_S(\text{gram}_n)}$$

Ces métriques, bien que limitées, fournissent une base de comparaison suffisante pour identifier les approches d'agents les plus prometteuses et guider les choix de conception.

Agent	TO	ROUGE	LLM-J	T(s)
Simple (VS + SQL)	N/A	0.45	0.53	10.6
Multi-agent (VS + SQL + DF + DS)	0.73	0.64	0.56	22.0
Sans VS (DF + DS)	N/A	0.25	0.48	29.5

Figure 6: Tableau de résultats pour les différentes approches d'agents. **TO** : trajectoire d'outils [0, 1], **ROUGE** : match de réponse finale (rouge score), **LLM-J** : LLM as a judge [0, 1]. **T(s)** : Temps d'exécution moyen (s)

4.2.4 Discussion

Les résultats obtenus mettent en évidence plusieurs tendances claires. L'approche multi-agent apparaît comme la plus pertinente : elle combine une trajectoire d'outils plus cohérente avec une meilleure précision des réponses finales, même si cela se fait au prix d'un temps d'exécution plus élevé. L'outil *document_finder*, indispensable dans ce schéma, constitue néanmoins un goulet d'étranglement en raison de sa lenteur. Par ailleurs, bien que coûteuse en temps de calcul, la lecture complète d'un document par le *document_specialist* conduit fréquemment à des réponses particulièrement précises, ce qui justifie son intégration sélective dans le pipeline.

Certaines limites méthodologiques doivent cependant être soulignées. La métrique *LLM-as-a-Judge*, bien que pratique, s'avère peu discriminante et attribue souvent des scores similaires à des réponses de qualité très variable. De plus, les temps d'exécution mesurés

¹Recall: Nombre d'éléments trouvés/Nombre d'éléments à trouver

sont surestimés : les expérimentations ont été menées depuis un poste de développement local, impliquant des allers-retours réseau non représentatifs d'un déploiement sur le cloud. Dans un environnement optimisé, ces délais seraient significativement réduits.

Enfin, des pistes d'amélioration existent, notamment en raffinant le prompt engineering pour déclencher la lecture multimodale uniquement lorsque nécessaire. Cela permettrait de limiter le recours coûteux au *document_specialist*, tout en préservant la qualité des réponses. Je me base sur ces éléments pour choisir l'approche multi-agent (VS + SQL + DF + DS) comme solution.

En conclusion, cette phase de recherche de solution m'a permis d'approfondir mes connaissances sur les LLMs et sur le fonctionnement des agents, tout en développant une meilleure compréhension de leurs atouts et de leurs limites. J'ai également progressé dans ma démarche scientifique, en comparant systématiquement plusieurs approches avant de retenir celle qui répond le mieux aux besoins du projet. La section suivante détaille le développement et la mise en œuvre concrète de la solution choisie.

5 Développement de la solution

Après avoir sélectionné et validé les méthodes d'extraction et de génération les plus adaptées, j'ai entamé la phase de développement de la solution. Cette section présente les choix techniques qui ont guidé la mise en œuvre, en décrivant à la fois les outils utilisés, le déploiement dans un environnement cloud, et l'implémentation de l'agent conversationnel.

L'ensemble du développement a été pensé pour être déployé dans le cloud : toutes les briques de la solution sont déployées au même endroit, de manière scalable et avec la possibilité d'être mises à jour ou relancées facilement. Une attention particulière a été portée à la pérennité de l'application, grâce à la documentation du code, au versioning, et à une gestion rigoureuse des dépendances. Je vais vous montrer, au long de cette section, le déroulement du développement de cette application.

5.1 Outils utilisés

Tout d'abord, il convient de vous introduire les outils que j'ai utilisés pour parvenir à l'application finale.

Pour la partie **code Python**, j'ai retenu deux librairies principales :

- **Docling** : une librairie récente de *layout parsing*, basée sur le modèle RT-DETR, qui permet d'extraire du texte et sa structure à partir de documents PDF hétérogènes. Cet outil a constitué un élément essentiel pour traiter les documents complexes et conserver autant que possible la hiérarchie logique.
- **Google-adk** : une librairie open source développée par Google, conçue pour créer et orchestrer des agents conversationnels. Elle est particulièrement adaptée à leur infrastructure et a servi de fondation pour la mise en place de l'agent intelligent de ce projet.

La solution a été déployée entièrement sur **Google Cloud Platform (GCP)**, en s'appuyant sur plusieurs services complémentaires :

- **Vertex AI** : plateforme GCP qui permet de créer, entraîner, personnaliser, déployer et surveiller des modèles d'intelligence artificielle à grande échelle.
- **BigQuery** : entrepôt de données serverless et hautement scalable permettant d'analyser rapidement de grandes quantités de données à l'aide du langage SQL.
- **Cloud Run** : service entièrement géré qui permet de déployer des conteneurs en production de manière scalable, sans gestion de l'infrastructure sous-jacente.
- **Cloud Storage** : service de stockage d'objets au format **S3**, utilisé pour stocker les données brutes, les fichiers pré-traités et l'ensemble des artefacts nécessaires au fonctionnement de la solution.

Enfin, pour gérer la configuration de l'infrastructure, j'ai utilisé **Terraform**. Cet outil d'infrastructure as code m'a permis de décrire, provisionner et gérer toutes les ressources cloud de manière déclarative et reproductible, garantissant une meilleure traçabilité et une maintenance facilitée de l'environnement.

5.2 Architecture de la solution

Avant d'entamer l'implémentation, nous avons pris le temps de concevoir une architecture cohérente pour l'ensemble de la solution. L'idée principale était de déployer tout le code Python dans des conteneurs exécutés directement sur le cloud, de façon à profiter de l'élasticité et de la scalabilité offertes par l'infrastructure GCP. J'ai donc naturellement utilisé les modèles de langage de la famille **Gemini** qui sont intégrés à cette plateforme.




Figure 7: Architecture globale de la solution : Le code applicatif tourne dans des conteneurs sur **Cloud Run**, quand un utilisateur pose une question à l'agent, celui-ci utilise les données extraites lors de l'ajout de documents par l'administrateur

L'architecture finale repose sur deux grandes briques : **l'extraction des données** et **l'agent conversationnel**.

Pour cette première brique, constituée d'un traitement **Docling**, d'étapes de post-traitement et de segmentation en chunks, le code est encapsulé dans un conteneur déployé sous la

forme d'un *Cloud Run Job*, le service d'exécution de conteneurs de Cloud Run. En termes de flux, les documents PDF bruts sont déposés dans un bucket (espace de stockage Cloud Storage), puis le conteneur lit ces fichiers en entrée, les transforme en texte structuré et segmenté, et enregistre le résultat dans des tables **BigQuery** dédiées (Une pour les chunks et une pour les métadonnées). Cette approche garantit un pipeline que l'on peut relancer à l'ajout de nouveaux documents.

La seconde brique est dédiée à l'agent conversationnel lui-même. Fondé sur **Google-adk**, le code est encapsulé dans un conteneur déployé en tant que *Cloud Run Service*, un autre service d'exécution de conteneurs. Ce service tourne en continu et est appelable via une FastAPI. Une API REST, développée par l'équipe, a été ajoutée en surcouche pour que le client puisse appliquer des filtres. L'agent repose ainsi sur la base vectorielle extraite dans BigQuery et interagit avec un modèle **Gemini** pour générer des réponses augmentées par les données.

Dans l'ensemble, cette architecture modulaire et cloud-native améliore la robustesse du traitement et la facilité de maintenance.




Figure 8: Pipeline d'extraction

5.3 Implémentation

J'ai été en grande partie seul à développer la solution, sauf sur la fin du stage où mon maître de stage a commencé à reprendre la main sur certains éléments. Mon rôle a donc

été d'écrire l'ensemble du code applicatif, tout en m'interfaçant avec l'équipe CEGG qui mettait à disposition des modules Terraform et des composants CI/CD que j'ai utilisés comme consommateur. Cette séparation des responsabilités m'a permis de me concentrer sur la partie applicative, tout en garantissant une intégration fluide dans l'infrastructure de l'entreprise.

5.3.1 Développement python

L'implémentation de la logique principale de mon code s'est fait en python pour les deux applications citées précédemment, l'extraction et l'agent.

Conscient du fait que mon code devait être repris par l'équipe après mon départ, j'ai veillé à produire une base claire et maintenable. J'ai rédigé une documentation détaillée expliquant les choix effectués, la logique des modules, et la manière d'exécuter ou de relancer chaque composant. Le code était systématiquement formaté et suivait un test de linting, afin d'éviter les incohérences et de maintenir un standard de qualité homogène. J'ai également cherché à limiter les dépendances externes au strict nécessaire, dans une logique de frugalité et de robustesse. Enfin, j'ai organisé le projet de manière modulaire, pour que chaque partie (extraction, nettoyage, chunking, génération de réponses) puisse être comprise, testée et adaptée indépendamment.




Figure 9: Logique d'extraction des chunks

5.3.2 Intégration continue

Une fois les applications développées, j'ai dû mettre en place leur intégration dans la chaîne CI/CD existante de l'entreprise. J'ai commencé par écrire les **Dockerfile** nécessaires pour conteneuriser chacune des deux applications. Chaque image Docker a ensuite été intégrée dans un pipeline d'intégration continue, où j'ai configuré des jobs dédiés au scan de sécurité, à la construction et à l'export des images vers le registre interne. J'ai utilisé pour cela et pour l'export des images vers GCP, des images maintenues par mon équipe, la CEGG.

Un point important a été de respecter le workflow Git déjà en place dans l'équipe : toute nouvelle fonctionnalité devait être développée dans une branche dédiée, soumise à une merge request et relue par au moins un autre membre de l'équipe avant intégration. Cette rigueur m'a permis d'assurer une meilleure qualité du code, de partager mes choix techniques, et de faciliter la reprise du projet par mes collègues.

5.3.3 Infrastructure Cloud

Au fil du développement, j'ai dû prendre en main Google Cloud Platform, un environnement cloud qui m'était jusqu'alors inconnu. Cette expérience m'a permis de me familiariser avec plusieurs concepts clés et bonnes pratiques pour la gestion d'infrastructures cloud.

J'ai notamment appris à écrire de l'**Infrastructure as Code (IaC)** avec **Terraform**, ce qui m'a permis de décrire, provisionner et gérer les ressources nécessaires au projet de manière reproductible. J'ai également découvert le principe de la **fédération d'identité cloud**, visant à limiter les droits des comptes au strict nécessaire et à appliquer les bonnes pratiques de sécurité.

L'utilisation du cloud a apporté plusieurs avantages significatifs pour le projet. La rapidité d'exécution est notable : grâce à la scalabilité de **Cloud Run**, il est possible de lancer en parallèle jusqu'à 100 tâches d'extraction de documents PDF, réduisant ainsi le temps de traitement global d'environ 24 heures à seulement 45 minutes.

Plus généralement, la scalabilité du cloud aide à ce que la solution puisse s'adapter à une augmentation du volume de données sans nécessiter de modification d'infrastructure. Le fait que toutes les briques de la solution (stockage, traitement, modèles) tournent au même endroit permet également de minimiser la latence.

5.3.4 Tests

J'ai mis en place différents types de tests afin d'ajouter des mesures de sécurités sur la solution, et de tendre vers une application robuste. Pour l'application d'extraction, j'ai développé des tests unitaires visant à vérifier le bon fonctionnement de chaque module (parsing, nettoyage, segmentation) ainsi que des tests d'intégration pour s'assurer que l'ensemble du pipeline produisait des résultats cohérents.

Pour l'agent conversationnel, j'ai implémenté des tests centrés sur la pertinence des

réponses : l'objectif était de vérifier que, pour un ensemble de questions types, le chatbot fournissait des réponses conformes à ce qui était attendu en moyenne. Cependant, j'ai rapidement constaté que tester un agent de ce type est remarquablement difficile. Les questions possibles sont très variées et parfois difficiles à imaginer, et les modèles de langage utilisés sont non déterministes par conception, ce qui fait que le même prompt peut générer des réponses différentes à chaque exécution. Ainsi, bien que ces tests aient permis de détecter certaines erreurs et d'itérer sur le code, ils ne suffisent pas à garantir une couverture exhaustive ni une validation parfaite des performances de l'agent en conditions réelles. Une évaluation complémentaire, basée sur des interactions utilisateurs réelles et sur des métriques qualitatives, serait nécessaire pour compléter cette phase.

Cette phase de développement m'a permis d'acquérir de nouvelles compétences techniques, notamment la prise en main de bibliothèques récentes pour l'extraction et le traitement de documents, ainsi que la maîtrise de services cloud et de pipelines CI/CD. Elle m'a également permis de renforcer des compétences déjà présentes, comme le développement Python, l'usage avancé de Git et la valorisation de données structurées pour en faire des informations exploitables par un agent conversationnel.

6 Conclusion

Ce stage m’a permis de relever la problématique complexe de l’extraction et de la valorisation d’informations contenues dans des documents PDF techniques d’un environnement industriel. À travers l’analyse du corpus, l’exploration de différentes méthodes fondées sur les modèles de langages et les agents, ainsi que le développement et le déploiement d’une solution cloud complète, j’ai pu acquérir une vision globale des défis techniques liés à ce type de projet. La solution mise en œuvre, combinant extraction, traitement structuré des documents et agent conversationnel intelligent, offre un moyen efficace et scalable de rendre l’information accessible aux utilisateurs métier.

Au-delà des aspects techniques, ce stage m’a offert une compréhension plus large des enjeux liés à l’industrialisation de solutions d’intelligence artificielle, où la robustesse, l’évolutivité et la pertinence métier constituent des critères essentiels. J’ai ainsi consolidé mes compétences en data science, en traitement de données, en déploiement cloud et en ingénierie logicielle, tout en développant une sensibilité accrue aux contraintes et exigences d’un contexte industriel.

Ce projet représente une première étape vers la mise en place d’outils d’assistance intelligente à la maintenance, dont le potentiel d’amélioration reste considérable. Il m’a permis d’allier apprentissage, autonomie et collaboration au sein d’une équipe experte, et constitue une expérience déterminante pour la suite de mon parcours professionnel.

En définitive, ce projet ouvre des perspectives intéressantes pour l’amélioration continue du système, notamment l’optimisation du temps de réponse, en ajustant les décisions de l’agent ou en proposant de nouveaux outils plus rapides. Au cours de conversation avec mon maître de stage, M. Barriere, j’ai pu me rendre compte de l’importance de la frugalité dans les applications, cela me laisse penser qu’une solution beaucoup moins lourde, sans extraction, pourrait-être industriellement meilleure que la solution performante retenue.

References

- [1] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *ECCV*, 2020.
- [2] Ruiqi Guo, Philip Sun, Erik Lindgren, Quan Geng, David Simcha, Felix Chern, and Sanjiv Kumar. Accelerating large-scale inference with anisotropic vector quantization, 2019.
- [3] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Marek Kukla, Pasquale Minervini, Xianliang Jiang, Edouard Chen, Edouard Grave, Luke Zettlemoyer, and Veselin Stoyanov. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [4] Nikolaos Livathinos, Christoph Auer, Maksym Lysak, Ahmed Nassar, Michele Dolfi, Panos Vagenas, Cesar Berrospi Ramis, Matteo Omenetti, Kasper Dinkla, Yusik Kim, Shubham Gupta, Rafael Teixeira de Lima, Valery Weber, Lucas Morin, Ingmar Meijer, Viktor Kuropiatnyk, and Peter W. J. Staar. Docling: An efficient open-source toolkit for ai-driven document conversion, 2025. Accepted to AAAI 25: Workshop on Open-Source AI for Mainstream Use, <https://doi.org/10.48550/arXiv.2501.17887>.
- [5] Birgit et al. Pfitzmann. Doclaynet: A large human-annotated dataset for document-layout analysis. *arXiv preprint arXiv:2212.08958*, 2022.
- [6] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5998–6008, 2017.
- [8] Yian Zhao, Wenyu Lv, Shangliang Xu, Jinman Wei, Guanzhong Wang, Qingqing Dang, Yi Liu, and Jie Chen. Detrs beat yolos on real-time object detection, 2024. v3, <https://doi.org/10.48550/arXiv.2304.08069>.

Annexes

A Annexe: Présentation du groupe Thales




Figure 10: Structure de l'entreprise

Le groupe Thales

Thales est un groupe industriel multinational français, historiquement connu sous le nom de Thomson-CSF, rebaptisé Thales en 2000. L'entreprise conçoit et fournit des systèmes, équipements et services dans les domaines de la défense, de l'aéronautique, de la sécurité, du transport terrestre et de l'espace. Fort de ses 77 000 collaborateurs répartis dans plus de 68 pays, Thales se positionne comme un acteur de référence dans la conception de systèmes critiques, à très haute fiabilité, où la sûreté, la sécurité et la résilience sont des enjeux centraux.

Les principales activités de Thales s'organisent autour de cinq grands secteurs :

- Défense et sécurité

- Aéronautique
- Espace
- Identité numérique et cybersécurité
- Technologies de l'information critiques

Ces domaines requièrent une forte intensité technologique, justifiant des investissements constants en R&D et une culture de l'innovation. Le groupe coopère également avec de nombreux partenaires industriels et institutionnels, en particulier dans le cadre de programmes nationaux et européens stratégiques.

La GBU SIX (Secure Information and Communications Systems)

Thales Digital Identity and Security (DIS), anciennement Thales SIX GTS, est l'une des Global Business Units (GBU) du groupe. Cette entité est spécialisée dans la conception de systèmes d'information sécurisés et résilients, intégrant les dernières avancées en matière de cybersécurité, de traitement du signal, de communication embarquée et de cloud souverain. Son objectif principal est de répondre aux besoins croissants en protection de l'information dans des environnements où les enjeux de confidentialité et d'intégrité sont majeurs.

La GBU SIX s'appuie sur une expertise technologique de pointe pour développer des solutions logicielles et matérielles à destination des opérateurs d'importance vitale (OIV), des gouvernements, et des grandes entreprises industrielles.

Thales Services Numériques (TSN)

Thales Services Numériques est une entité transverse de Thales chargée d'apporter des prestations d'ingénierie numérique à l'ensemble des GBU du groupe ainsi qu'à des clients externes. TSN regroupe des expertises dans le développement logiciel, le traitement de données massives (Big Data), le cloud computing, la cybersécurité, l'intelligence artificielle et les systèmes d'information complexes.

L'entité propose des services allant du conseil technologique à l'implémentation de solutions complètes, avec un fort accent mis sur l'innovation continue et l'industrialisation des pratiques DevOps et MLOps. TSN joue donc un rôle de catalyseur technologique, en fournissant des briques logicielles réutilisables, des plateformes d'industrialisation, et des expertises transverses à l'échelle du groupe.

Le site de Mérignac, où est réalisé ce stage, constitue l'un des pôles techniques majeurs de TSN en région Nouvelle-Aquitaine. Il regroupe plusieurs dizaines d'ingénieurs et de consultants spécialisés dans les domaines de la data science, du cloud, de l'automatisation, et des architectures critiques.

Le pôle Data & Artificial Intelligence (DAI)

TSN est organisé en plusieurs pôles techniques, chacun centré sur un domaine d'expertise spécifique :

- Conseil et Transformation Digitale
- Smart Critical Systems
- User-Centric Solutions
- Data & Artificial Intelligence (DAI)
- Automation Platform & Cloud
- Cybersécurité et Infogérance Critique

Le pôle **DAI**, auquel je suis rattaché, regroupe les ingénieurs et chercheurs spécialisés en traitement de données, en machine learning, en intelligence artificielle explicable (XAI), ainsi qu'en ingénierie des données. Il intervient sur des projets à forte composante analytique, dans des secteurs variés : énergie, transport, défense, finance ou encore industrie.

Ce pôle a pour mission de :

- Concevoir des solutions basées sur l'IA répondant à des besoins métiers spécifiques
- Déployer des plateformes d'analyse et d'orchestration de données à grande échelle
- Encadrer l'incubation de projets IA, du prototype à l'industrialisation

Il est dirigé sur le site de Mérignac par Benoît Fessenmeyer.

La Cellule d'Expertise et de Gouvernance Google Cloud (CEGG)

Le projet sur lequel je travaille est incubé au sein de la **CEGG**, une cellule technique transverse au sein du pôle DAI. Cette équipe a été constituée pour répondre aux enjeux spécifiques des projets cloud-native utilisant Google Cloud Platform (GCP), en particulier dans le cadre de partenariats stratégiques comme celui établi avec EDF.

La CEGG assure plusieurs missions :

- Assurer une veille technologique sur l'écosystème GCP
- Définir des standards de développement et d'architecture sur le cloud Google
- Accompagner les projets dans l'adoption des bonnes pratiques (MLOps, CI/CD, gouvernance de données)
- Incuber des projets data complexes, comme celui du chatbot MMESI

L'équipe est pluridisciplinaire, composée de profils complémentaires :

- 1 Team Leader (salariée EDF)
- 2 Data Scientists
- 1 DevOps Engineer
- 1 Product Owner
- 3 Architectes Cloud/Data
- 1 Stagiaire Data Scientist (moi)

Mon rôle au sein de l'équipe

Intégré à la CEGG en tant que Data Scientist stagiaire, mon rôle consiste à travailler sur l'un des projets d'expérimentation portés par l'équipe : le développement et surtout l'évaluation d'un agent conversationnel doté de système RAG (Retrieval-Augmented Generation) pour le compte d'EDF.

Ce projet nécessite d'aborder la chaîne complète de traitement des données, depuis l'extraction de documents complexes jusqu'à l'interfaçage avec un LLM, en passant par le déploiement d'une infrastructure cloud scalable. Ma mission porte plus spécifiquement sur :

- Le développement en python de la logique d'extraction et des agents
- L'analyse de la pertinence des résultats fournis par l'agent conversationnel
- Le développement de métriques d'évaluation pertinentes

B Annexe: Exemple de document pdf

Les documents PDF que j'ai traité sont strictement confidentiels, car ils décrivent les règles et des cas d'usages (données sensibles) à suivre dans les CNPE (Centres Nucléaires de Production d'Electricité) français. Je ne pouvais donc pas les partager dans ce rapport.

Cependant, il est intéressant pour la compréhension du lecteur de pouvoir se représenter la **structure** de ces documents. J'ai donc construit dans cette annexe un exemple de document avec des données factices. Vous pourrez y voir des tableaux à structure complexe, s'étalant parfois sur plusieurs pages, ainsi qu'un grand nombre de captures d'écran censées expliquer des procédures. Cela illustre bien la difficulté d'extraire des données propres de ceux-ci.

Pour remplir ce document de données factices, je me suis permis **un trait d'humour** en faisant référence à l'un de mes films préférés. J'espère que vous, lecteurs, ne m'en tiendrez pas rigueur, et saurez reconnaître là une manière maladroite de vous présenter à quoi ressemblent ces PDF.

"Devant la violence de cette scène nous préférons vous montrer ce documentaire consacré à la langouste." - Mission Cléopâtre



DOCUMENTAIRE SUR LA LANGOUSTE

DIV BIOLOGIE MARINE

Contrairement à une idée largement répandue, la langouste se nourrit exclusivement de fruits de mer.
Ce qui ne l'empêche pas de rester très humaine.

Référence:	LAN202300001
Applicabilité :	Observations sur la vie marine

Rédaction	Contrôle	Approbation	Visa final (*)
Jacques Le Poisson 08/06/2021	Marie La Méduse 10/06/2021	René Le Requin 11/06/2021	✓

Résumé: Ce cas d'usage a pour objet principal de décrire le cycle de vie fascinant de la langouste, de son éclosion à sa maturité.

Affaire: Observation des écosystèmes marins

Projet(s): Programme Biodiversité Océanique

Référence technique : Éthologie des crustacés

() La présence de cette icône atteste que le document a été approuvé par signature électronique
Ne peut être transmis à l'extérieur de DIV_BIOLOGIE MARINE et entités autorisées.*

DIRECTION DE LA BIOLOGIE marine
OCEANOGRAPHIE

1, Rue de l'Océan 75001
PARIS CEDEX 01

Téléphone: 01.01.01.01.01
Télécopie : www.biomarinenews.com

BIODIVERSITE MARINE SAS au capital de 1 000 000,00 euros
500 000 000 RCS Paris
Siège social: 1, Rue de l'Océan
75001 Paris - France

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.

Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

SOMMAIRE

1. PRESENTATION DU CONTEXTE	4
(a) - OBJET DU DOCUMENT	4
(b) - PRESENTATION DU CONTEXTE	4
(c) - PERIMETRE DU PROCESSUS COUVERT PAR LE CAS D'USAGE.	4
(d) - OBJECTIFS ET POINTS CLES ABORDES DANS LE CAS D'USAGE	4
(e) - PRINCIPAUX ACTEURS DU PROCESSUS	5
(f) - CORRECTIFS ATTENDUS	5
(g) - DOCUMENTS ASSOCIES.	5
2. DEROULEMENT DU CAS D'USAGE	6
(a) - SYMBOLES UTILISES	6
(b) - LA PONTE DES ŒUFS	6
(c) - SUIVRE LE DEVELOPPEMENT DES LARVES	8
(d) - OBTENIR LA VIE ADULTE.	11
3. ANNEXES	15
(a) - ANNEXE 1: SYNOPTIQUE DU CAS D'USAGE.	15

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.


Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

1 PRESENTATION DU CONTEXTE

1.1 Objet du document

Ce document décrit les étapes clés du cycle de vie de la langouste, de la ponte des œufs à l'émergence des juvéniles, afin de comprendre leur développement et leur habitat.

1.2 Présentation du contexte



Un synoptique du cycle de vie est disponible en Annexe 1.

1.3 Périmètre du processus couvert par le cas d'usage

Le cas d'usage couvre :

- La ponte des œufs par la femelle reproductrice,
- Le développement des larves dans le plancton,
- La métamorphose et l'établissement des juvéniles sur le fond marin.

1.4 Objectifs et points clés abordés dans le cas d'usage

Les objectifs sont :

- Comprendre le processus de reproduction de la langouste,
- Observer les différentes phases larvaires,
- Identifier les facteurs environnementaux clés pour leur survie.

Phase du Cycle de Vie	Description Générale	Principales tiques	Caractéris-
Ponte et Incuba- tion	La femelle fécondée pond des milliers d'œufs.	Les œufs sont transportés sous l'abdomen de la femelle pendant plusieurs mois.	
Développement Larvaire (Phyllo- some)	Les œufs éclosent en larves microscopiques qui dérivent dans le plancton.	Les larves passent par plusieurs mues et stades morphologiques (Phyllosomes), se nourrissant de plancton.	
Métamorphose et Juvénile	La larve subit une transformation radicale pour ressembler à une petite langouste.	Le juvénile migre vers le fond marin et cherche un abri dans les récifs ou les grottes.	
Vie Adulte et Re- production	La langouste grandit, mue régulièrement, atteint la maturité sexuelle et se reproduit.	Les adultes sont des chasseurs opportunistes, vivant souvent dans des terriers ou des crevasses. La reproduction perpétue le cycle.	

1.5 Principaux acteurs du processus

Les principaux acteurs du processus sont :

- La femelle langouste reproductrice,
- Le plancton océanique,
- Les prédateurs des larves,
- Les écosystèmes récifaux et rocheux pour l'établissement des juvéniles.

1.6 Correctifs attendus

Pas de correctifs attendus pour ce documentaire naturel.

1.7 Documents associés

Publication scientifique : "Les Mystères de la Langouste"

Table 1: Corrélation entre stades larvaires de langoustes (Phyllo-some) et paramètres océanographiques clés.

ID Échantillon	Date (UTC)	Stade Phyllo- some	Densité (larves/m³)	Température (°C) (sur- face)	Salinité (psu) (sur- face)	Profondeur (m)	Chlorophylle a (µg/L) (sur- face)	Observations Spécifiques (Prédation, etc.)
CY23-101	2023-07- 15 08:30	Phyllosome I	12.5	25.1	35.2	10	0.85	Présence d'une petite méduse dans l'échantillon

Table 1 – suite

ID Échantillon	Date (UTC)	Stade Phyllo- some	Densité (larves/m ³)	Température (°C) (sur- face)	Salinité (psu) (sur- face)	Profondeur (m)	Chlorophylla (µg/L) (sur- face)	Observations Spécifiques (Prédation, etc.)
CY23-102	2023-07-15 09:15	Phyllosome II	8.0	25.0	35.2	15	0.88	Vents faibles, courant dominant Sud-Ouest
CY23-103	2023-07-15 10:00	Phyllosome I	15.2	24.9	35.3	5	0.92	Zone de forte concentration de zooplancton
CY23-104	2023-07-16 07:00	Phyllosome III	5.5	24.8	35.4	20	0.78	Détection d'une espèce de copépode prédateur
CY23-105	2023-07-16 08:45	Phyllosome II	9.8	24.9	35.3	12	0.82	Turbulence modérée
CY23-106	2023-07-16 10:30	Phyllosome IV	3.2	24.7	35.4	25	0.75	Observation d'un comportement de fuite par les larves
CY23-107	2023-07-17 08:00	Phyllosome I	18.0	25.2	35.1	8	0.95	Forte présence de diatomées
CY23-108	2023-07-17 09:30	Phyllosome II	10.5	25.1	35.2	14	0.89	Conditions stables
CY23-109	2023-07-17 11:00	Phyllosome III	7.0	25.0	35.3	18	0.80	Accélération du courant
CY23-110	2023-07-18 07:30	Phyllosome V (post-métamorphose)	1.5	24.6	35.4	30	0.70	Juvenile rencontré à proximité, possible migration vers le fond
CY23-111	2023-07-18 09:00	Phyllosome III	6.8	24.7	35.3	22	0.77	Vents plus forts
CY23-112	2023-07-18 10:45	Phyllosome IV	4.0	24.5	35.5	28	0.68	Zone de remontée d'eaux plus profondes

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.

Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

2 DEROULEMENT DU CAS D'USAGE

Chaque langouste femelle doit pondre ses œufs dans des conditions optimales. L'interaction (fécondation et incubation) avec le mâle est essentielle. Par la suite, la libération des larves dans le plancton permet leur dispersion. Une fois les larves développées, elles se métamorphosent pour devenir des juvéniles.

2.1 Symboles utilisés

Légende des symboles utilisés dans le document :



Observation importante ou fait remarquable

2.2 La ponte des œufs

Données d'entrée : La femelle langouste est prête à pondre, ayant accumulé suffisamment d'énergie.

Chemin d'accès: Zone de reproduction sous-marine

Phase de ponte :

- La femelle fécondée transporte des millions d'œufs sous son abdomen, attachés par des filaments.
- La période d'incubation peut durer plusieurs mois, variant selon l'espèce et la température de l'eau.
- Elle protège activement ses œufs des prédateurs et assure leur oxygénation.

Observation importante : Les œufs sont d'abord d'un vert vif, puis deviennent plus foncés à mesure que l'embryon se développe.

2.3 Suivre le développement des larves

2.3.1 Les différentes étapes larvaires

Données d'entrée : Les œufs ont éclos, libérant des larves microscopiques dans la colonne d'eau. Le journal de bord océanographique IOP311 : Suivi des populations larvaires de langoustes permet d'observer la répartition et la densité des larves.

Chemin d'accès : Océanographie > Secteur Larvaire > Rapports d'études > P03... > P03-2... > IOP311 - Suivi des retours populations larvaires

Journal de bord IOP311 :

- Collecter des échantillons de plancton à différentes profondeurs.
- Identifier les différentes stades larvaires de langoustes (phyllosomes).
- Estimer la biomasse larvaire et analyser les courants porteurs.

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.

Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

2.3.2 Interactions dans le milieu planctonique

Au cours de leur vie pélagique, les larves de langoustes interagissent avec d'autres organismes marins. Si des conditions environnementales défavorables surviennent, elles peuvent être plus vulnérables. L'observation de ces interactions est cruciale pour comprendre leur taux de survie.

Nota: enregistrer ces observations dans les journaux de bord permet de retracer les facteurs de succès ou d'échec des générations passées.

Journal de bord des observations :

- Noter les espèces planctoniques présentes dans les échantillons.
- Documenter les interactions observées (prédation, compétition).

2.3.3 Observer la métamorphose

Une fois le stade larvaire avancé, les larves subissent une métamorphose pour ressembler davantage à des langoustes adultes. Il est essentiel de vérifier que cette transformation s'est bien déroulée.

Observations de métamorphose : Cliquer sur le lien **Stades de développement** (1).

Analyse des juvéniles : Les **observations de terrain** (1) indiquent la présence de juvéniles formés, prêts à s'établir.


Nota: après la métamorphose réussie, les juvéniles cherchent des habitats appropriés pour se fixer. Cette phase est critique pour la survie des jeunes langoustes.

Données de sortie : Les larves ont complété leur développement et se sont métamorphosées en juvéniles. Les juvéniles sont maintenant prêts à explorer leur nouvel environnement.


2.4 Obtenir la vie adulte

2.4.1 Établissement des juvéniles

Données d'entrée : Les juvéniles langoustes sont prêts à quitter la colonne d'eau pour s'installer sur le fond marin.




Observation des habitats : Cliquer sur l'option 02. Identifier les zones d'établissement privilégiées (1).



langouste_juvenile_etabli.png

Cliquer sur l'option 03. **Observer le comportement de colonisation** (1).



langouste_reproduction_adulte.png

Accès au cycle reproducteur : Cliquer sur le bouton 'Accéder aux données de reproduction' (1).

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.

Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

2.4.2 Atteindre la maturité sexuelle


Une fois installés dans leur habitat, les juvéniles grandissent et se développent. Ils atteindront la maturité sexuelle après plusieurs années, période pendant laquelle ils mue et grandissent progressivement.

Étape de croissance : Cliquer sur l'option 07. **Observer la croissance et les mues** (1).

Données de sortie : Les langoustes sont désormais adultes et capables de se reproduire, complétant ainsi le cycle de vie. La reproduction pourra à nouveau commencer.

3 ANNEXES

3.1 Annexe 1: Synoptique du cas d'usage



langouste_synoptique_cycle.png

Ce document contient des informations sensibles relevant de la vie marine et juridiquement protégées.

Il est réservé à l'usage exclusif des personnes désignées comme destinataires du document et/ou autorisées à y accéder. Il est illégal de photocopier, distribuer, divulguer, ou d'utiliser de toute autre manière les informations contenues dans ce document sans accord du service émetteur.

Copyright BIODIVERSITE MARINE SAS - 2021. Ce document est la propriété de BIODIVERSITE MARINE SAS

C Annexe : Exemple de chunks pour les différents parsers

Vous pouvez observer ci-dessous un échantillon de chunks (paragraphes) extrait par les différents parsers évalués. Pour chaque image, les chunks sont délimités entre eux par des tirets : -----

```
Observationdeshabitats: Cliquersurl'option02. Identifierleszonesd'etablissementprivilegiees (1).
langouste_juvenile_etabli.png
Cliquer sur l'option 03. Observer le comportement de colonisation (1).
langouste_reproduction_adulte.png
Acces au cycle reproducteur : Cliquer sur le bouton 'Acceder aux donnees de reproduction' (1).
2.4.2 Atteindre la
-----
(cid:6)(cid:6)(cid:6)(cid:6)(cid:123)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6) L'interaction (fécondation et incubation)
(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)N\
```

Figure 11: Chunks extraits avec le BasicParser (témoin): on peut y voir des chunks mal nettoyés et découpés au milieu des phrases

```
Chaque langouste femelle doit pondre ses œufs dans des conditions optimales.
  (cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:123)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6)(cid:6) L'inter
-----
## 1 PRESENTATION DU CONTEXTE
-----
## 2.3 Suivre le developpement des larves
-----
## 2.4.2 Atteindre la maturite sexuelle
Une fois installes dans leur habitat, les juveniles grandissent et se developpent. Ils atteindront la maturite sexuelle apres p
Etape de croissance : Cliquer sur l'option 07. Observer la croissance et les mues (1). Donnees de sortie : Les langoustes sont
```

Figure 12: Chunks extraits avec le DoclingParser, observable : des sections très courtes et des caractères mal traduits résultant en bruit

```
1.6 Correctifs attendus
Pas de correctifs attendus pour ce documentaire naturel.
-----
2 DEROULEMENT DU CAS D'USAGE
Chaque langouste femelle doit pondre ses œufs dans des conditions optimales. L'interaction (fécondation et incubation) avec le male est es
-----
Sommaire
1. PRESENTATION DU CONTEXTE .....4 (a) - OBJET DU DOCUMENT .....
2. DEROULEMENT DU CAS D'USAGE .....6 (a) - SYMBOLES UTILISES .....
3. ANNEXES .....15 (a) - ANNEXE 1: SYNOPTIQUE DU CA
```

Figure 13: Chunks extraits avec le GeminiParser


```

## 2.3.2 Interactions dans le milieu planctonique
Au cours de leur vie pelagique, les larves de langoustes interagissent avec d'autres organismes marins. Si des conditions enviro
Journal de bord des observations :
Nota: enregistrer ces observations dans les journaux de bord permet de retracer les facteurs de succes ou d'echec des generatio
- · Noter les especes planctoniques presentes dans les echantillons.
- · Documenter les interactions observees (predation, competition).
-----
## 1.1 Objet du document
Ce document decrit les etapes cles du cycle de vie de la langouste, de la ponte des œufs a l'emergence des juveniles, afin de c

```

Figure 14: Chunks extraits avec le `LayoutParser` (solution retenue): on observe des sections bien extraites