

meo.desbois-renaudin@thalesgroup.com

Projet de fin d'études

Valorisation de données PDF par multi-agent RAG

10/09/2025

Version : 2.1

Méo DESBOIS-RENAUDIN
Etudiant

Paul BARRIERE
Tuteur entreprise

Floréal MORANDAT
Tuteur académique

www.thalesgroup.com



Contexte : Employé TSN en mission pour EDF



> Thales Services Numériques est une ESN

- Entreprise de services numériques
- Propose des prestations informatiques pour des entreprises/ministères

> Mon équipe : La CEGG

- Développe des applications pour répondre à des besoins Data/IA d'EDF
- Déploie une infrastructure Google Cloud pour supporter ces applications

> Pourquoi ce stage ?


Problématique

> ~200 documents PDF de 50 pages

- ▶ Très récurrent dans les grandes entreprises
- ▶ Censé avoir une structure commune

> Actuellement accessible par mail sur demande

- ▶ Surcharge les boîtes mail
- ▶ Restreint l'accès aux documents



Récupérer le texte des documents PDF

> Une tâche ardue

- Format pensé pour être imprimé
- Pas de structure claire : des caractères et leurs coordonnées

> Solution finale

- Layout parsing basé sur RT-DETR pour retrouver la structure
- Post-processing : Nettoyage, déletion des doublons
- Découpage par section





Figure : Exemple de glyphe dans un PDF



[1] Carion et al., End-to-End Object Detection with Transformers, ECCV 2020

L'accès aux documents par les employés EDF



> Le besoin :

- Doit permettre à l'employé d'accéder à une information rapidement
- Doit être facilement pris en main par tous les différents métiers des CNPE
- Doit répondre à des types de questions variés



> Pourquoi utiliser une solution LLM?

- Comprends n'importe quelle phrase en langage naturel
- Empiriquement efficace
- Permet l'utilisation de différents outils (voir suite agents)


Retrieval-Augmented Generation (RAG)

> Problème : Données non vues à l'entraînement

- Données confidentielles d'entreprises
- Comment donner au LLM ces informations ?

> Solution : Moteur de recherche intégré

- Ajout dans le prompt d'informations
- Le plus souvent : recherche sémantique grâce à des modèles d'embedding




Retrieval-Augmented Generation (RAG)

> Problème : Données non vues à l'entraînement

- Données confidentielles d'entreprises
- Comment donner au LLM ces informations ?

> Solution : Moteur de recherche intégré

- Ajout dans le prompt d'informations
- Le plus souvent : recherche sémantique grâce à des modèles d'embedding



Agents LLM


> Idée principale

- Un modèle de langage qui peut utiliser des outils externes (fonctions)
- Par exemple : peut effectuer une recherche vectorielle

> Fonctionnement

- Un modèle fondation, entraîné sur des exemples d'utilisation d'outils
- Exécution de code (outils) lorsque le modèle génère une séquence de tokens spécifique

```
<tool_call>
  <tool_name>get_weather</tool_name>
  <parameters>
    <param_name>city</param_name>
    <param_value>London</param_value>
  </parameters>
</tool_call>
```



Nos sources d'informations




> Des métadonnées sur les Documents

- Métadonnées classiques : Titre, date de création, version, ID.
- Un résumé du document généré par LLM



> Le texte brut des documents

- Découpés par sections (taille ~80 mots)
- Accessible via Recherche vectorielle sémantique



> Les documents eux mêmes

- Stockés au format PDF
- Lisible grâce à un VLM (Vision Language Model)


Approches

> Sources d'informations en tant qu'outils appelables

- Outil de recherche vectorielle (recherche sémantique)
- Outil de requête SQL read-only *libre* sur les métadonnées et le texte brut
- Outil *document_finder* : Trouver le nom exact d'un document (agent as a tool)
- Outil *document_specialist* : Lire un document via VLM à partir du nom exact de celui-ci (sous-agent)

> 3 méthodes envisagées

- Agent simple : Recherche vectorielle (RV) + requête SQL
- Agent multimodal : Recherche et lecture de document via VLM
- Multi-agent complet : RV + SQL + VLM



Comment évaluer un agent conversationnel?

Méthode d'évaluation retenue

Construire un jeu de données annoté

Permet de comparer la réponse de l'agent à une réponse « idéale »

Métriques considérées

- Méthode simple : ROUGE score sur la réponse finale
- Trajectoire d'outils : Quels outils ont été appelés par l'agent?
- LLM as a Judge : Utiliser un modèle de langage pour noter la réponse de l'agent
- Temps d'exécution d'une requête

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Reference Summaries}\}} \sum_{\text{gram}_n \in S} \min(\text{Count}_{\text{cand}}(\text{gram}_n), \text{Count}_S(\text{gram}_n))}{\sum_{S \in \{\text{Reference Summaries}\}} \sum_{\text{gram}_n \in S} \text{Count}_S(\text{gram}_n)}$$

Résultats

Agent	TO	ROUGE	LLM-J	T(s)
Simple (VS + SQL)	N/A	0.45	0.53	10.6
Multi-agent (VS + SQL + DF + DS)	0.73	0.64	0.56	22.0
Sans VS (DF + DS)	N/A	0.25	0.48	29.5

A noter

- Les temps d'exécutions sont plus long que sur l'application déployée
- LLM as a Judge donne peu de différences de score

Discussion

Agent	TO	ROUGE	LLM-J	T(s)
Simple (VS + SQL)	N/A	0.45	0.53	10.6
Multi-agent (VS + SQL + DF + DS)	0.73	0.64	0.56	22.0
Sans VS (DF + DS)	N/A	0.25	0.48	29.5


> Lenteur « document_finder »

- Agent as a tool : chronophage
- Mais la lecture par VLM donne les meilleures réponse

> Meilleure solution : Multi-agent

- Le rouge score est représentatif -> simple
- Donne les meilleurs résultats avec la combinaison de RV + VLM

Développement de la solution



> Choix d'EDF : Google Cloud Platform

- ▶ Déléguer la gestion de l'infrastructure
- ▶ Applications robustes et reproductibles

> Outils utilisés

- ▶ Code source : Python
- ▶ Infrastructure : Terraform
- ▶ Agents : Google Agent Development kit

Conclusion

> Aujourd'hui

- Application en fin de développement
- Mis en production en octobre

> Apprentissage personnel

- Data science
- Méthodologie scientifique
- LLM, Cloud, agents

> Le début de ma carrière ...

Sources

1. Carion et al., *End-to-End Object Detection with Transformers*, ECCV 2020
2. Guo et al., *Anisotropic Vector Quantization for Large-Scale Inference*, 2019
3. Lewis et al., *Retrieval-Augmented Generation for NLP*, NeurIPS 2020
4. Livathinos et al., *Docling Toolkit*, AAAI Workshop 2025
5. Pfizmann et al., *DocLayNet Dataset*, arXiv 2022
6. Redmon et al., *YOLO: Real-Time Object Detection*, CVPR 2016
7. Vaswani et al., *Attention Is All You Need*, NeurIPS 2017
8. Zhao et al., *DETRs vs. YOLOs in Real-Time Detection*, arXiv 2024



THALES
Building a future we can all trust

Merci

Méo DESBOIS-RENAUDIN

Etudiant



0607766315



meo.desbois-renaudin@thalesgroup.com